

СТАТИСТИКА БОЛЬШИХ ДАННЫХ – ИДЗ 2

Студент: Эспинола Ривера, Хольгер Элиас

Тема: Статистический анализ динамики изменений наблюдаемой характеристики с течением времени

Для когорты индивидов проведены измерения исследуемой характеристики Y в моменты времени t_1, \dots, t_d (Visit), расстояние между которыми одинаково. Помимо исследуемой характеристики измерялись сопутствующие факторы A (не меняющаяся со времени характеристика, измеряемая в момент начала исследования) и B (меняющаяся со временем характеристика, измерение которой проводилось в каждой временной точке). Из таблицы данных следует выбрать значения описанных характеристики, с персональным значением переменной "Variant".

Вопросы

1. Загрузить данные и отфильтровать строки с персональным значением переменной "Variant".

Применение филтра для выбора данных для варианта 9:

```
> # collect the data which corresponds to variant n° 9
```

```
> datavar9 <- dataset[dataset$Variant == 9, -1]
```

```
> print(head(datavar9))
```

	ID	Y	A	B	Visit
19579	1	54.16743	1	1	0
19580	1	33.62468	1	1	1
19581	1	16.39175	1	2	2
19582	1	40.94266	1	2	3
19583	1	31.66774	1	2	4
19584	2	41.43027	0	1	0

```
> print("Dimensions dataset - Variant 9")
```


[1] "Dimensions dataset - Variant 9"

```
> print(dim(datavar9))
```

[1] 4405 5

2. Изобразить графически результаты наблюдений без учета времени измерений исследуемой характеристики. В предположении нормальности значений наблюдаемого признака провести двухфакторный дисперсионный анализ зависимости наблюдаемого признака от значений факторов А и В.

А) График построена:



В) Двухфакторный дисперсионный анализ

Шаг 01: Модель взаимодействия между факторов А и В

$$\eta_{ij} = \mu + \alpha_i^A + \alpha_j^B + \alpha_{ij}^{AB}$$

```
> qab <- lm(Y ~ as.factor(A) * as.factor(B), data = datavar9)
> qab
```

Call:

```
lm(formula = Y ~ as.factor(A) * as.factor(B), data = datavar9)
```

Coefficients:

(Intercept)	as.factor(A)1
38.354	7.679
as.factor(B)2	as.factor(A)1:as.factor(B)2
-6.149	-8.971

Шаг 02: Аддитивные модели

- Факторы А и В:

$$\eta_{ij} = \mu + \alpha_i^A + \alpha_j^B$$

```
> qadd <- lm(Y ~ as.factor(A) + as.factor(B), data = datavar9)
> qadd
```

Call:

```
lm(formula = Y ~ as.factor(A) + as.factor(B), data = datavar9)
```

Coefficients:

(Intercept)	as.factor(A)1	as.factor(B)2
40.49	3.11	-10.33

- Только Фактор A:

$$\eta_{ij} = \mu + \alpha_i^A$$

```
> qa <- lm(Y ~ as.factor(A), data = datavar9)
```

```
> qa
```

Call:

```
lm(formula = Y ~ as.factor(A), data = datavar9)
```

Coefficients:

(Intercept)	as.factor(A)1
35.217	3.128

- Только фактор B:

$$\eta_{ij} = \mu + \alpha_j^B$$

```
> qb <- lm(Y ~ as.factor(B), data = datavar9)
```

```
> qb
```

Call:

```
lm(formula = Y ~ as.factor(B), data = datavar9)
```

Coefficients:

(Intercept)	as.factor(B)2
41.94	-10.34

- Независимые от факторов A и B:

$$\eta_{ij} = \mu$$

```
> q0 <- lm(Y ~ 1, data = datavar9)
```

```
> q0
```

Call:

```
lm(formula = Y ~ 1, data = datavar9)
```

Coefficients:

(Intercept)
36.68

Шаг 03: Проверка гипотез для двухфакторный дисперсионный анализ

Пусть модель: $\eta_{ij} = \mu + \alpha_i^A + \alpha_j^B + \alpha_{ij}^{AB}$

А) Гипотеза отсутствия взаимодействий

$$H_{AB} : \alpha_{ij}^{AB} = 0$$

```
> anova(qadd, qab)
```

Analysis of Variance Table

Model 1: Y ~ as.factor(A) + as.factor(B)

Model 2: Y ~ as.factor(A) * as.factor(B)

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	4402	401345				
2	4401	379295	1	22050	255.85	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Гипотеза H_{AB} **отвергает**, следовательно, есть влияние взаимодействия между A и B.

Б) Гипотеза отсутствие влияния фактора A

$$H_{AB} : \alpha_{ij}^{AB} = 0 ; H_A : \alpha_i^A = 0$$

```
> anova(qa, qab)
```

Analysis of Variance Table

Model 1: Y ~ as.factor(A)

Model 2: Y ~ as.factor(A) * as.factor(B)

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	4403	518919				
2	4401	379295	2	139624	810.03	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Гипотезы H_{AB} и H_A **отвергают**, следовательно, есть аддитивный влияние фактора A.

В) Гипотеза отсутствие влияния фактора В

$$H_{AB} : \alpha_{ij}^{AB} = 0 ; H_B : \alpha_j^B = 0$$

```
> anova(qb, qab)
```

Analysis of Variance Table

Model 1: Y ~ as.factor(B)

Model 2: Y ~ as.factor(A) * as.factor(B)

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	4403	411951				
2	4401	379295	2	32656	189.45	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Гипотезы H_{AB} и H_B **отвергают**, следовательно, есть аддитивный влияние фактора В.

Г) Гипотеза независимости Y от факторов А, В.

$$H_{AB} : \alpha_{ij}^{AB} = 0 ; H_A : \alpha_i^A = 0 ; H_B : \alpha_j^B = 0$$

```
> anova(q0, qab)
```

Analysis of Variance Table

Model 1: Y ~ 1

Model 2: Y ~ as.factor(A) * as.factor(B)


	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	4404	529645				
2	4401	379295	3	150350	581.51	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Гипотезы H_{AB} , H_A и H_B отвергают

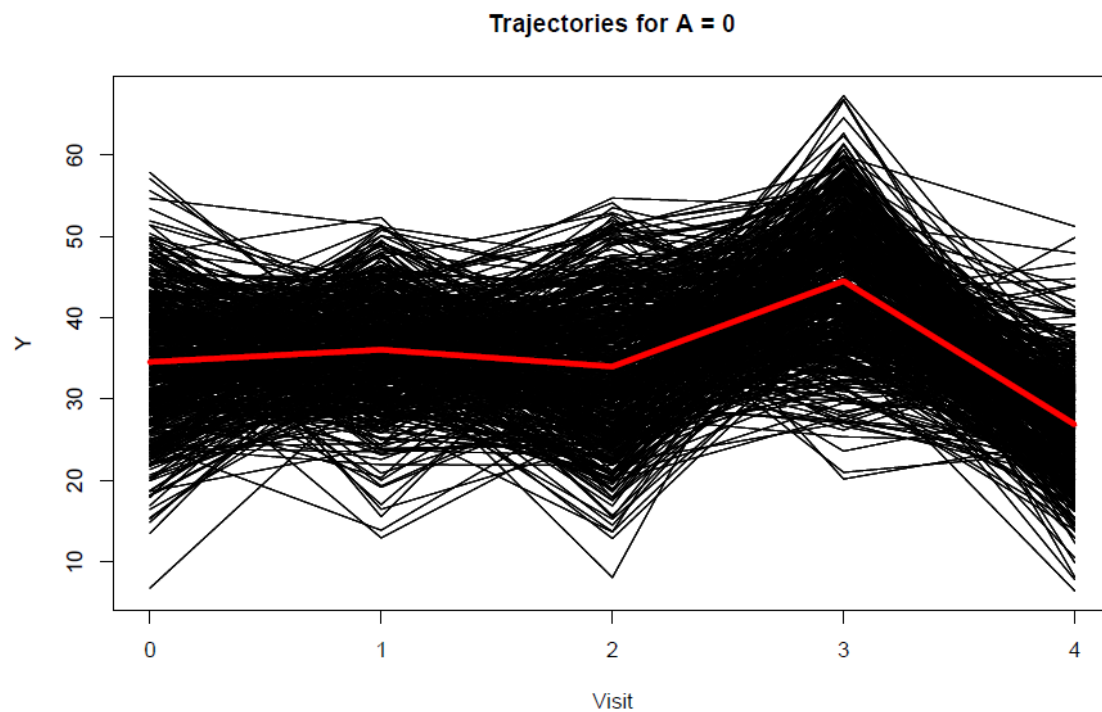
3. Преставить визуально динамику изменений наблюдаемого признака в виде траекторий и оценить наличие влияния постоянного фактора А на значения измеряемого признака. Оценить корреляции значений наблюдаемого признака в различные моменты времени при каждом значений признака А без учета влияния признака В.

А) График построена динамику изменений наблюдаемого признака




Б) Оценить наличие влияния постоянного фактора A на значения Y .

- Траектория динамику Y (во времени) для $A = 0$



- Траектория динамику Y (во времени) для $A = 1$



В) Оценить корреляции значения Y (во времени) при каждом значения A.

Выявляем возможные значения переменной A

```
> lvA = levels(as.factor(datavar9$A))
```

```
[1] "0" "1"
```

Корреляционная матрица для Y (во времени) при A = 0

```
> corr_A0
```

```
$`A=0`$corr
```

	Y_V0	Y_V1	Y_V2	Y_V3	Y_V4
Y_V0	1.00000000	-0.026984902	-0.036062662	-0.04480147	0.05599858
Y_V1	-0.02698490	1.00000000	0.008961128	0.09223862	0.02129035
Y_V2	-0.03606266	0.008961128	1.00000000	-0.07581508	0.05553220
Y_V3	-0.04480147	0.092238617	-0.075815077	1.00000000	-0.05049627
Y_V4	0.05599858	0.021290351	0.055532204	-0.05049627	1.00000000

Корреляционная матрица для Y (во времени) при A = 1

```
> corr_A1
```

```
$`A=1`$corr
```

	Y_V0	Y_V1	Y_V2	Y_V3	Y_V4
Y_V0	1.00000000	0.017432803	0.01894922	0.034281278	-0.02109358
Y_V1	0.01743280	1.00000000	-0.04929156	-0.001735304	0.06703278
Y_V2	0.01894922	-0.049291562	1.00000000	-0.039914042	0.02080742
Y_V3	0.03428128	-0.001735304	-0.03991404	1.00000000	-0.06104107
Y_V4	-0.02109358	0.067032779	0.02080742	-0.061041066	1.00000000

4. Построит оценки средних значений наблюдаемой характеристики при различных значениях факторов А и В и центрировать исходные наблюдения. С использованием семивариограммы, оценить зависимость корреляции значений центрированного процесса от времени в предположении его стационарности при каждом значении пары факторов А и В.

Шаг 01: Для оценить средних значений наблюдаемой характеристики при различных значениях факторов А и В, получить смещенную линейную модель по каждому пары значений факторов А и В.

```
> # generate the linear mixed effect model for each pair values A, B
> m0 <- NULL
> for(i in names(d9)){
  m0[[i]] <- lme(Y ~ as.factor(Visit), random = ~1|ID, data = d9[[i]])
}
```

Шаг 02: Построить семивариограммы по каждому пары значений факторов А и В.

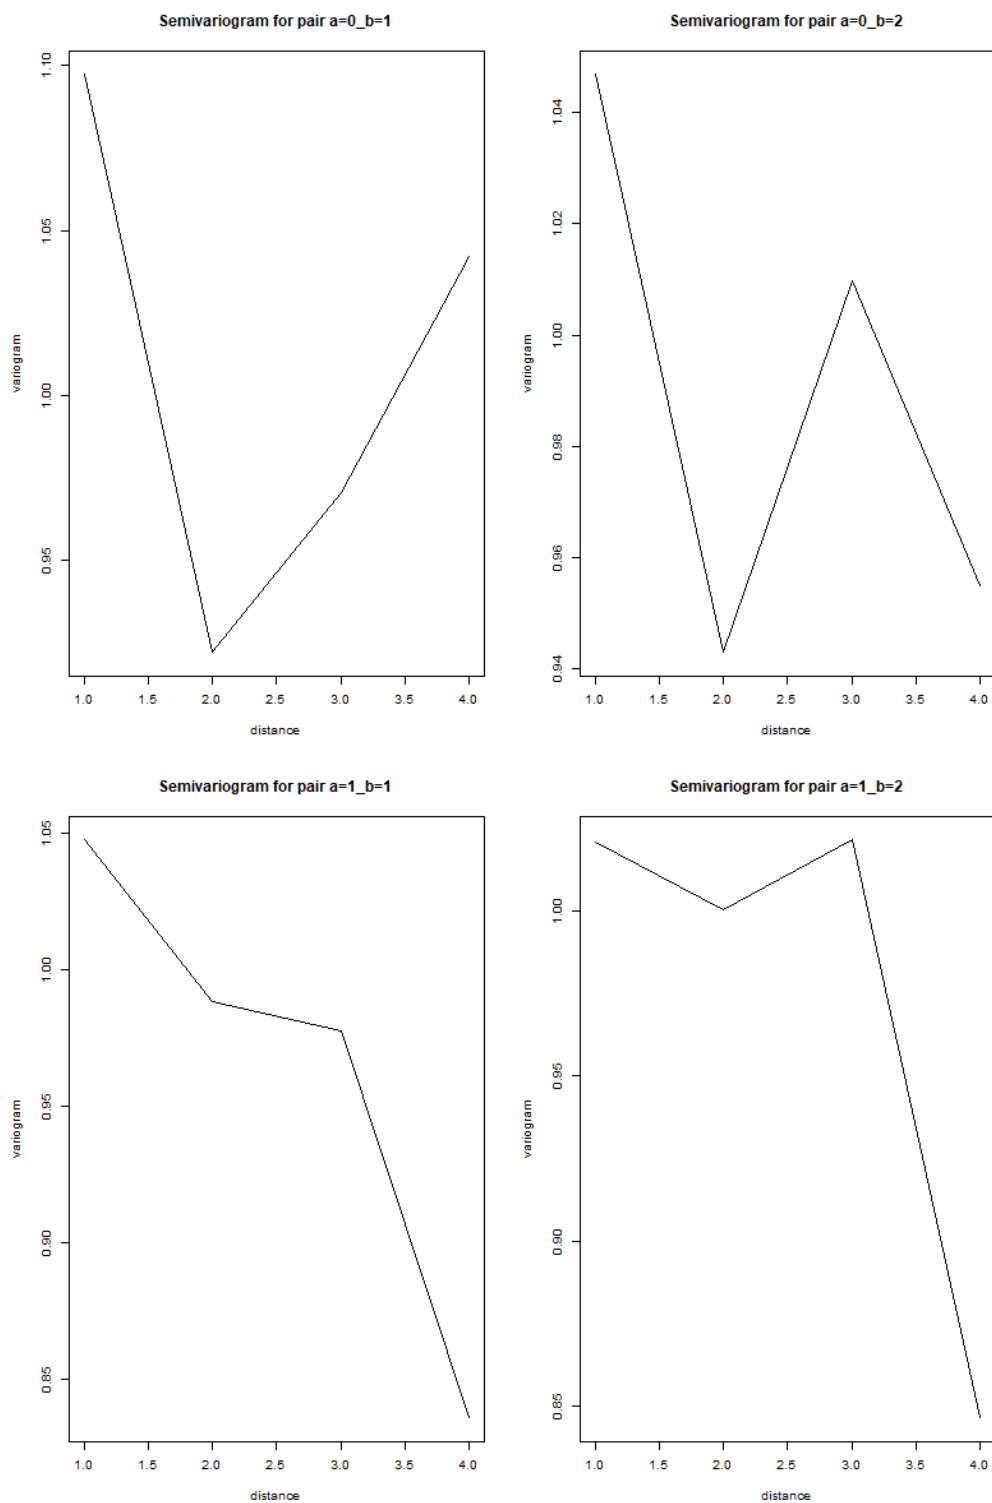
Таблички:

```
> # check the table of semi-variogram distances and variogram values
```

\$`a=0_b=1`				\$`a=0_b=2`			
	variog	dist	n.pairs		variog	dist	n.pairs
1	1.0975740	1	445	1	1.0469750	1	504
2	0.9219419	2	330	2	0.9429442	2	367
3	0.9705741	3	232	3	1.0097347	3	243
4	1.0422249	4	121	4	0.9548429	4	110

\$`a=1_b=1`				\$`a=1_b=2`			
	variog	dist	n.pairs		variog	dist	n.pairs
1	1.0479601	1	398	1	1.0206838	1	419
2	0.9884016	2	304	2	1.0002901	2	336
3	0.9778377	3	210	3	1.0216352	3	213
4	0.8359854	4	97	4	0.8464707	4	111

Графики семивариограммы:



Шаг 03: Оценить зависимость корреляции значений центрированного процесса от времени в предположении его стационарности при каждом значении пары факторов A и B

```
> print(corr)
```

```
$`a=0_b=1`$corr
```

	[Visit = 0]	[Visit = 1]	[Visit = 2]	[Visit = 3]	[Visit = 4]
[1,]	1.00000000	-0.09757398	0.07805808	0.02942590	-0.04222494
[2,]	-0.09757398	1.00000000	-0.09757398	0.07805808	0.02942590
[3,]	0.07805808	-0.09757398	1.00000000	-0.09757398	0.07805808
[4,]	0.02942590	0.07805808	-0.09757398	1.00000000	-0.09757398
[5,]	-0.04222494	0.02942590	0.07805808	-0.09757398	1.00000000

```
$`a=0_b=2`$corr
```

	[Visit = 0]	[Visit = 1]	[Visit = 2]	[Visit = 3]	[Visit = 4]
[1,]	1.00000000	-0.046974985	0.05705581	-0.009734725	0.045157074
[2,]	-0.046974985	1.00000000	-0.04697499	0.057055806	-0.009734725
[3,]	0.057055806	-0.046974985	1.00000000	-0.046974985	0.057055806
[4,]	-0.009734725	0.057055806	-0.04697499	1.00000000	-0.046974985
[5,]	0.045157074	-0.009734725	0.05705581	-0.046974985	1.00000000

```
$`a=1_b=1`$corr
```

	[Visit = 0]	[Visit = 1]	[Visit = 2]	[Visit = 3]	[Visit = 4]
[1,]	1.00000000	-0.04796008	0.01159842	0.02216233	0.16401459
[2,]	-0.04796008	1.00000000	-0.04796008	0.01159842	0.02216233
[3,]	0.01159842	-0.04796008	1.00000000	-0.04796008	0.01159842
[4,]	0.02216233	0.01159842	-0.04796008	1.00000000	-0.04796008
[5,]	0.16401459	0.02216233	0.01159842	-0.04796008	1.00000000

```
$`a=1_b=2`$corr
```

	[Visit = 0]	[Visit = 1]	[Visit = 2]	[Visit = 3]	[Visit = 4]
[1,]	1.00000000	-0.02068379	-0.00029010	-0.02163522	0.15352928
[2,]	-0.02068379	1.00000000	-0.02068379	-0.00029010	-0.02163522
[3,]	-0.00029010	-0.02068379	1.00000000	-0.02068379	-0.00029010
[4,]	-0.02163522	-0.00029010	-0.02068379	1.00000000	-0.02068379
[5,]	0.15352928	-0.02163522	-0.00029010	-0.02068379	1.00000000

5. Построить смешанную линейную с простым эффектом индивида, а также смешанную линейную модель, допускающую линейную зависимость эффекта индивида от времени.

Шаг 01: Построение смешанную линейную модель с простым эффектом индивида.

```
> # Build linear mixed effect model (lme) with simple individual effect
> q51 <- lme(fixed = Y ~ as.factor(Visit), random =~ 1|ID,
+          data = datavar9, method = "ML")
> print(q51)
```

Linear mixed-effects model fit by maximum likelihood

Data: datavar9

Log-likelihood: -16039.02

Fixed: Y ~ as.factor(Visit)

(Intercept)	as.factor(Visit)1	as.factor(Visit)2	as.factor(Visit)3
36.0884731	1.0633315	-0.5996778	10.5155339
as.factor(Visit)4			
-8.0404377			

Random effects:

Formula: ~1 | ID

	(Intercept)	Residual
StdDev:	1.447286	9.118381

Number of Observations: 4405

Number of Groups: 881

Шаг 02: Построение смешанную линейную модель с линейную зависимость эффекта индивида от времени

```
> # Linear mixed model with linear dependency between individual effect and  
time  
> q52 <- lme(fixed = Y ~ as.factor(Visit), random =~ (1 + Visit)|ID,  
+           data = datavar9, method = "ML")  
> print(q52)
```

Linear mixed-effects model fit by maximum likelihood

Data: datavar9

Log-likelihood: -16039.02

Fixed: Y ~ as.factor(Visit)

(Intercept)	as.factor(Visit)1	as.factor(Visit)2	as.factor(Visit)3
36.0884731	1.0633315	-0.5996778	10.5155339

as.factor(Visit)4

-8.0404377

Random effects:

Formula: $\sim(1 + \text{Visit}) \mid \text{ID}$

Structure: General positive-definite, Log-Cholesky parametrization

	StdDev	Corr
(Intercept)	1.4472896795	(Intr)
Visit	0.0004759267	-0.001
Residual	9.1183808651	


Number of Observations: 4405

Number of Groups: 881

Шаг 03: Чтобы определить если целесообразность введения коэффициента наклона случайного эффекта, мы пользуем критерия cAIC.

```
> # apply cAIC criteria to establish the best model
> tblcAIC <- data.frame(models = c(model1, model2),
+                       cAICvalues = c(q51_cAIC$caic, q52_cAIC$caic))
>
> # table of cAIC values
> print(tblcAIC)
```

	models	cAICvalues
1	y ~ Visit + (1 ID)	32087.86
2	y ~ Visit + (1+Visit ID)	32099.03



Модель 1 является лучшей моделью, так как она имеет более низкое значение индекса cAIC.

6. С учетом результатов п.5, построить смешанную модель зависимости наблюдаемого признака от значений признаков А и В с учетом времени наблюдения. При каждом значении фактора А проверить гипотезы аддитивности влияния фактора В и времени наблюдения а также гипотезы отсутствия влияния каждого из факторов В и времени наблюдения. Включить в модель фактор А и оценить влияние фактора А на значение наблюдаемой характеристики.

Шаг 01: Смешанная модель зависимости А, В и времени наблюдения с простым эффектом индивида: $\eta_{ijk} = \mu + \alpha_i^A + \alpha_j^B + \alpha_k^T + \alpha_{ij}^{AB} + \alpha_{ik}^{AT} + \alpha_{jk}^{BT} + \alpha_{ijk}^{ABT}$

```
> # mixed model: (Y|A, B, Visit)
> # model: nij = u + aA_i + aB_j + aT_k +
> #          aA_i * aB_j + aA_i * aT_k + aB_j * aT_k + aABT_ijk
> q61 <- lme(fixed = Y ~ as.factor(A) * as.factor(B) * as.factor(Visit),
+           random =~ 1|ID, data = datavar9, method = "ML")
```

Linear mixed-effects model fit by maximum likelihood

Data: datavar9

Fixed: Y ~ as.factor(A) * as.factor(B) * as.factor(Visit)

(Intercept)	as.factor(A)1:as.factor(B)2	as.factor(A)1:as.factor(B)2:as.factor(Visit)1
39.6987827	-7.5762389	-1.6467547
as.factor(A)1	as.factor(A)1:as.factor(Visit)1	as.factor(A)1:as.factor(B)2:as.factor(Visit)2
7.6186228	-0.6507950	-1.2982832
as.factor(B)2	as.factor(A)1:as.factor(Visit)2	as.factor(A)1:as.factor(B)2:as.factor(Visit)3
-10.2483269	0.3873670	-0.3697754
as.factor(Visit)1	as.factor(A)1:as.factor(Visit)3	as.factor(A)1:as.factor(B)2:as.factor(Visit)4
-3.1754012	-0.1745915	-0.4951229
as.factor(Visit)2	as.factor(A)1:as.factor(Visit)4	
0.9867510	-1.1514323	
as.factor(Visit)3	as.factor(B)2:as.factor(Visit)1	
10.9074422	9.4057480	
as.factor(Visit)4	as.factor(B)2:as.factor(Visit)2	
-14.1641351	-2.3935396	
	as.factor(B)2:as.factor(Visit)3	
	-1.3219062	
	as.factor(B)2:as.factor(Visit)4	
	13.0831640	


```
Random effects:
Formula: ~1 | ID
(Intercept) Residual
StdDev:    0.7247436 6.431324

Number of Observations: 4405
Number of Groups: 881
```


Шаг 02: Модель для взаимодействия между фактора В и времени наблюдения по каждому значения фактора А: $\eta_{jk} = \mu + \alpha_j^B + \alpha_k^T + \alpha_{jk}^{BT}$

> # interaction model for factor B and time (for each value of A)

> # model: nij = u + aB_j + aT_k + aBT_jk

> q6_intBT

```
$`A=0`
Linear mixed-effects model fit by maximum likelihood
Data: datavar9[datavar9$A == idx, ]
Log-likelihood: -7719.06
Fixed: Y ~ as.factor(B) * as.factor(Visit)
              (Intercept)          as.factor(B)2
              39.7013396         -10.2534407
      as.factor(Visit)1      as.factor(Visit)2
              -3.1777745              0.9825991
      as.factor(Visit)3      as.factor(Visit)4
              10.9028203         -14.1659785
as.factor(B)2:as.factor(Visit)1 as.factor(B)2:as.factor(Visit)2
              9.4105095              -2.3854028
as.factor(B)2:as.factor(Visit)3 as.factor(B)2:as.factor(Visit)4
              -1.3128631              13.0867806

Random effects:
Formula: ~1 | ID
              (Intercept) Residual
StdDev:      0.5251229  6.439798

Number of Observations: 2350
Number of Groups: 470
```

```
$`A=1`
Linear mixed-effects model fit by maximum likelihood
Data: datavar9[datavar9$A == idx, ]
Log-likelihood: -6756.805
Fixed: Y ~ as.factor(B) * as.factor(Visit)
              (Intercept)          as.factor(B)2
              47.316026         -17.821977
      as.factor(Visit)1      as.factor(Visit)2
              -3.823295              1.376311
      as.factor(Visit)3      as.factor(Visit)4
              10.739890         -15.302130
as.factor(B)2:as.factor(Visit)1 as.factor(B)2:as.factor(Visit)2
              7.753412              -3.695932
as.factor(B)2:as.factor(Visit)3 as.factor(B)2:as.factor(Visit)4
              -1.706449              12.561395

Random effects:
Formula: ~1 | ID
              (Intercept) Residual
StdDev:      0.9018753  6.421413

Number of Observations: 2055
Number of Groups: 411
```

Шаг 03: Аддитивный модель для фактора В и времени наблюдения по каждому значения фактора А: $\eta_{jk} = \mu + \alpha_j^B + \alpha_k^T$

> # additive model for factor B and time (for each value of A)

> # model: njk = u + aB_j + aT_k

> q6_addBT

```
$`A=0`
Linear mixed-effects model fit by maximum likelihood
Data: datavar9[datavar9$A == idx, ]
Log-likelihood: -7966.97
Fixed: Y ~ as.factor(B) + as.factor(Visit)
              (Intercept)          as.factor(B)2 as.factor(Visit)1 as.factor(Visit)2
              37.8217600         -6.4942815          1.6477217         -0.3800583
as.factor(Visit)3 as.factor(Visit)4
              10.1168904         -7.8408942

Random effects:
Formula: ~1 | ID
              (Intercept) Residual
StdDev:      0.3187778  7.172675

Number of Observations: 2350
Number of Groups: 470
```

```
$`A=1`
Linear mixed-effects model fit by maximum likelihood
Data: datavar9[datavar9$A == idx, ]
Log-likelihood: -6965.95
Fixed: Y ~ as.factor(B) + as.factor(Visit)
              (Intercept)          as.factor(B)2 as.factor(Visit)1 as.factor(Visit)2
              45.7284596         -14.8425713          0.1919292         -0.6092956
as.factor(Visit)3 as.factor(Visit)4
              10.1498450         -8.9119120

Random effects:
Formula: ~1 | ID
              (Intercept) Residual
StdDev:      1.218979  7.077988

Number of Observations: 2055
Number of Groups: 411
```

Шаг 04: Аддитивный модель только для фактора времени по каждому значения фактора A: $\eta_{jk} = \mu + \alpha_k^T$

> # additive model for time (for each value of A)

> # model: njk = u + aT_k

> q6_addT

```
$`A=0`  
Linear mixed-effects model fit by maximum likelihood  
Data: datavar9[datavar9$A == idx, ]  
Log-likelihood: -8185.204  
Fixed: Y ~ as.factor(Visit)  
      (Intercept) as.factor(Visit)1 as.factor(Visit)2 as.factor(Visit)3  
      34.5746193      1.5095455      -0.5596874      9.9510789  
as.factor(Visit)4  
      -7.6889004  
  
Random effects:  
Formula: ~1 | ID  
      (Intercept) Residual  
StdDev: 0.002015962 7.878417  
  
Number of Observations: 2350  
Number of Groups: 470
```

```
$`A=1`  
Linear mixed-effects model fit by maximum likelihood  
Data: datavar9[datavar9$A == idx, ]  
Log-likelihood: -7709.621  
Fixed: Y ~ as.factor(Visit)  
      (Intercept) as.factor(Visit)1 as.factor(Visit)2 as.factor(Visit)3  
      37.8196442      0.5530623      -0.6454089      11.1610178  
as.factor(Visit)4  
      -8.4424389  
  
Random effects:  
Formula: ~1 | ID  
      (Intercept) Residual  
StdDev: 0.002904375 10.30575  
  
Number of Observations: 2055  
Number of Groups: 411
```

Шаг 05: Аддитивный модель только для фактора B по каждому значения фактора A: $\eta_{jk} = \mu + \alpha_j^B$

> # additive model for factor B (for each value of A)

> # model: njk = u + aB_j

> q6_addB

```
$`A=0`
Linear mixed-effects model fit by maximum likelihood
Data: datavar9[datavar9$A == idx, ]
Log-likelihood: -8545.669
Fixed: Y ~ as.factor(B)
(Intercept) as.factor(B)2
      38.354372      -6.149092

Random effects:
Formula: ~1 | ID
(Intercept) Residual
StdDev: 0.0004598311 9.184493

Number of Observations: 2350
Number of Groups: 470
```

```
$`A=1`
Linear mixed-effects model fit by maximum likelihood
Data: datavar9[datavar9$A == idx, ]
Log-likelihood: -7517.637
Fixed: Y ~ as.factor(B)
(Intercept) as.factor(B)2
      46.033372      -15.12015

Random effects:
Formula: ~1 | ID
(Intercept) Residual
StdDev: 0.0004920496 9.386562

Number of Observations: 2055
Number of Groups: 411
```

Шаг 06: Проверка гипотезы

H_BT: Гипотеза аддитивности влияния фактора В и времени наблюдения

$$H_{BT} : \alpha_{jk}^{BT} = 0$$

H_B: Гипотеза отсутствие влияния фактора В

$$H_{BT} : \alpha_{jk}^{BT} = 0 ; H_B : \alpha_j^B = 0$$

H_T: Гипотеза отсутствие влияния фактора времени наблюдения

$$H_{BT} : \alpha_{jk}^{BT} = 0 ; H_T : \alpha_k^T = 0$$

> # check the p-values to make the hypothesis inference

> print(tbl_hypothesis())

	A = 0	A = 1
H_BT: bBT_ij = 0	5.372022e-106	3.106080e-89
H_B: bBT_ij = 0 and bB_i = 0	2.733439e-199	0.000000e+00
H_T: bBT_ij = 0 and bT_j = 0	0.000000e+00	2.964394e-323

Шаг 07: Заключение

Для A = 0 и A = 1:

Гипотеза H_BT **отвергает**, тогда есть влияние взаимодействия между фактора В и времени наблюдения

Гипотезы H_BT и H_B **отвергают**, тогда есть аддитивности влияния фактора В

Гипотезы H_BT и H_T **отвергают**, тогда есть аддитивности влияния фактора времени наблюдения

Шаг 08: Построить модель с отсутствием влияния фактора A

$$\eta_{ijk} = \mu + \alpha_j^B + \alpha_k^T + \alpha_{jk}^{BT}$$

> # model without factor A

```
> q62 <- lme(fixed = Y ~ as.factor(B) * as.factor(Visit),
+           random = ~ 1|ID, data = datavar9, method = "ML")
```

```
Linear mixed-effects model fit by maximum likelihood
Data: datavar9
Log-likelihood: -14793.27
Fixed: Y ~ as.factor(B) * as.factor(Visit)
              (Intercept)          as.factor(B)2
              43.111498          -13.628380
as.factor(Visit)1          as.factor(Visit)2
              -3.286819           1.285314
as.factor(Visit)3          as.factor(Visit)4
              11.193819          -14.607156
as.factor(B)2:as.factor(Visit)1 as.factor(B)2:as.factor(Visit)2
              8.441592           -3.140770
as.factor(B)2:as.factor(Visit)3 as.factor(B)2:as.factor(Visit)4
              -1.860544           12.693484

Random effects:
Formula: ~1 | ID
              (Intercept) Residual
StdDev:      1.600061 6.785727

Number of Observations: 4405
Number of Groups: 881
```

Шаг 09: Оценить влияние фактора A на значение наблюдаемой характеристика Y

Пусть модели:

Модель 1: $\eta_{ijk} = \mu + \alpha_j^B + \alpha_k^T + \alpha_{jk}^{BT}$

Модель 2: $\eta_{ijk} = \mu + \alpha_i^A + \alpha_j^B + \alpha_k^T + \alpha_{ij}^{AB} + \alpha_{ik}^{AT} + \alpha_{jk}^{BT} + \alpha_{ijk}^{ABT}$

Гипотеза H_A: $H_A: \alpha_i^A = \alpha_{ij}^{AB} = \alpha_{ik}^{AT} = \alpha_{ijk}^{ABT} = 0$

```
> # study the influence of factor A
```

```
> anov_addA <- anova(q62, q61)
```

```
> print(anov_addA)
```

	Model	df	AIC	BIC	logLik	Test	L.Ratio	p-value
q62	1	12	29610.53	29687.22	-14793.27			
q61	2	22	28996.08	29136.67	-14476.04	1 vs 2	634.452	<.0001


```
> print(paste("p-value = ", anov_addA$p-value[2]))
```

```
[1] "p-value = 7.26550582148688e-130"
```

Шаг 10: Заключение

Гипотеза H_A **отвергает**, тогда есть влияние фактора A на значение наблюдаемой характеристики.

```
> # check cAIC values  
> q62_aic <- cAIC(q62)$caic  
> print(q62_aic)  
[1] 29586.8  
> q61_aic <- cAIC(q61)$caic  
> print(q61_aic)  
[1] 28996.23
```



С критерием AIC, тоже видим что модель с влияния фактора A – это лучшее модель чем модель с отсутствием влияния фактора A.

8. Построить смешанную модель ковариационного анализа в предположении полиномиальной зависимости второго порядка наблюдаемого признака от времени. Проверить гипотезу линейности зависимости среднего значения наблюдаемого признака от времени в присутствии факторов A и B.

Шаг 01: Построить смешанную модель для полиномиальной зависимости второго порядка наблюдаемого признака от времени

$$\eta_{ijkl} = \mu + \alpha_i^A + \alpha_j^B + \alpha_k^T + \alpha_l^{T^2} + \alpha_{ij}^{AB} + \alpha_{ik}^{AT} + \alpha_{jk}^{BT} + \alpha_{il}^{AT^2} + \alpha_{jl}^{BT^2} + \alpha_{ijk}^{ABT} + \alpha_{ijl}^{ABT^2}$$

```
> # build model mixed-analysis for 2nd polynomial order in time
> # model: nijkl = u + aA_i + aB_j + aT_k + aT^2_l +
> #       aAB_ij + aAT_ik + aBT_jk + aAT^2_il + aBT^2_jl +
> #       aABT_ijk + aABT^2_ijl
> q8.abt_square <- lme(fixed = Y ~ as.factor(A) * as.factor(B) * Visit +
+       as.factor(A) * as.factor(B) * Visit2,
+       random =~ 1|ID, data = datavar9, method = "ML")
> print(q8.abt_square)
```

```
Linear mixed-effects model fit by maximum likelihood
Data: datavar9
Log-likelihood: -15637.05
Fixed: Y ~ as.factor(A) * as.factor(B) * Visit + as.factor(A) * as.factor(B) * Visit2
              (Intercept)              as.factor(A)1
              36.1461399              6.8813034
              as.factor(B)2              Visit
              -6.4161795              9.4532502
              Visit2              as.factor(A)1:as.factor(B)2
              -2.7506763              -7.3154050
              as.factor(A)1:Visit              as.factor(B)2:Visit
              1.1078696              -5.0909960
              as.factor(A)1:Visit2              as.factor(B)2:Visit2
              -0.2627845              1.6993514
              as.factor(A)1:as.factor(B)2:Visit as.factor(A)1:as.factor(B)2:Visit2
              -1.9759779              0.4198586

Random effects:
Formula: ~1 | ID
              (Intercept) Residual
StdDev: 0.0006608732 8.422465

Number of Observations: 4405
Number of Groups: 881
```

```
> # check the significance for each coefficient
> anova(q8.abt_square)
```

```
> anova(q8.abt_square)
```

	numDF	denDF	F-value	p-value
(Intercept)	1	3514	83301.34	<.0001
as.factor(A)	1	879	150.79	<.0001
as.factor(B)	1	3514	1652.90	<.0001
Visit	1	3514	67.47	<.0001
Visit2	1	3514	653.11	<.0001
as.factor(A):as.factor(B)	1	3514	294.38	<.0001
as.factor(A):Visit	1	3514	0.15	0.7017
as.factor(B):Visit	1	3514	76.13	<.0001
as.factor(A):Visit2	1	3514	0.02	0.8914
as.factor(B):Visit2	1	3514	155.45	<.0001
as.factor(A):as.factor(B):Visit	1	3514	0.68	0.4110
as.factor(A):as.factor(B):Visit2	1	3514	1.90	0.1683

Шаг 02: Построить смешанную модель с линейности зависимости среднего значения наблюдаемого признака от времени в присутствии факторов А и В

$$\eta_{ijk} = \mu + \alpha_i^A + \alpha_j^B + \alpha_k^T + \alpha_{ij}^{AB} + \alpha_{ik}^{AT} + \alpha_{jk}^{BT} + \alpha_{ijk}^{ABT}$$

```
> # build model mixed-analysis for linear dependency
> # model: nij = u + aA_i + aB_j + aT_j + aAB_ij + aAT_ik + aBT_jk
> q8.abt_linear <- lme(fixed = Y ~ as.factor(A) * as.factor(B) * Visit,
+                       random =~ 1|ID, data = datavar9, method = "ML")
> print(q8.abt_linear)
```

```
Linear mixed-effects model fit by maximum likelihood
Data: datavar9
Log-likelihood: -15999.27
Fixed: Y ~ as.factor(A) * as.factor(B) * Visit
      (Intercept)          as.factor(A)1          as.factor(B)2          Visit
      41.58498944          7.60481559          -9.73325341          -1.60139570
as.factor(A)1:as.factor(B)2          as.factor(A)1:Visit
      -8.40876955          0.05699598
as.factor(B)2:Visit          as.factor(A)1:as.factor(B)2:Visit
      1.77965432          -0.30380007

Random effects:
Formula: ~1 | ID
      (Intercept) Residual
StdDev: 0.0006331532 9.144316

Number of Observations: 4405
Number of Groups: 881
```

Шаг 03: Проверка гипотеза линейности зависимости

$$H_{T^2} : \alpha_l^{T^2} = \alpha_{il}^{AT^2} = \alpha_{jl}^{BT^2} = \alpha_{ijl}^{ABT^2} = 0$$

```
> # proof of hypothesis for linear dependency
> # H_T^2: bABT^2_ijl = 0 and bAT^2_il = 0 and bBT^2_jl = 0 and bT^2_l = 0
> q8_anova1 <- anova.lme(q8.abt_linear, q8.abt_square)
```

```

> print(q8_anova1)
      Model   df   AIC      BIC   logLik  Test L.Ratio p-value
q8.abt_linear  1  10 32018.55 32082.45 -15999.27
q8.abt_square  2  14 31302.10 31391.57 -15637.05 1 vs 2 724.4463 <.0001
>
> # check the p-value for H_T^2
> q8_pvalue1 <- q8_anova1$"p-value"[2]
> print(q8_pvalue1)
[1] 1.772828e-155

```

Шаг 04: Заключение:

Гипотеза отвергает, тогда есть влияние по полиномиальной зависимости второго порядка.

```

> # check the AIC values
> q8square_caic <- cAIC(q8.abt_square)$caic
> print(q8square_caic)
[1] 31308.41
> q8linear_caic <- cAIC(q8.abt_linear)$caic
> print(q8linear_caic)
[1] 32029.95

```



С использованием условного информационного критерия Акаике (сAIC), видим что модель второго порядка для времени наблюдения – это лучшее чем просто линейной зависимости

9. С использованием информационных критериев AIC и BIC, выбрать наилучшую модель для неслучайного эффекта в рамках смешанной модели с простым эффектом индивида. Провести исследование влияния факторов А, В и времени наблюдения на значение исследуемой характеристики в рамках данной модели.

Сравнить результаты, полученные с использованием AIC, и выбор наилучшей модели с учетом случайного эффекта при помощи cAIC.

Шаг 01: Проверяем значения информационных критериев AIC и BIC для каждой рассматриваемой модели.

```
> # build the information-criteria table which contains AIC and BIC values
> IC_table <- data.frame(model = func, AIC = aic_values, BIC = bic_values)
> print(IC_table)
```

	model	AIC	BIC
1	Y ~ A*B*Visit	32018.55	32082.45
2	Y ~ A*B + A*Visit + B*Visit	32017.15	32074.66
3	Y ~ A*B + A*Visit	32085.20	32136.32
4	Y ~ A*B + B*Visit	32015.39	32066.52
5	Y ~ A*Visit + B*Visit	32273.62	32324.74
6	Y ~ A*Visit + B	32337.57	32382.30
7	Y ~ A + B*Visit	32271.64	32316.37
8	Y ~ A*B + Visit	32083.33	32128.06
9	Y ~ A*Visit	33487.26	33525.60
10	Y ~ B*Visit	32389.20	32427.54
11	Y ~ A + B + Visit	32335.57	32373.91
12	Y ~ A + Visit	33485.34	33517.29
13	Y ~ B + Visit	32449.83	32481.78
14	Y ~ Visit	33574.13	33599.69
15	Y ~ A*B*Visit + A*B*Visit2	31302.10	31391.57
16	Y ~ A*B*Visit + A*Visit2 + B*Visit2	31302.00	31385.08
17	Y ~ A*B*Visit + A*Visit2	32018.55	32082.45
18	Y ~ A*B*Visit + B*Visit2	31300.10	31376.79
19	Y ~ A*B + A*Visit + A*Visit2 + B*Visit + B*Visit2	31300.68	31377.37
20	Y ~ A*B + A*Visit + A*Visit2	31522.85	31586.75
21	Y ~ A*B + B*Visit + B*Visit2	31297.06	31360.96
22	Y ~ A*B + Visit + Visit2	31519.00	31570.13
23	Y ~ A*Visit + A*Visit2 + B*Visit + B*Visit2	31584.30	31654.59
24	Y ~ A*Visit + A*Visit2	33096.96	33148.08
25	Y ~ B*Visit + B*Visit2	31712.15	31763.27
26	Y ~ A*Visit2	33398.01	33436.35
27	Y ~ B*Visit2	32209.50	32247.84
28	Y ~ A + B + Visit + Visit2	31788.69	31833.42
29	Y ~ A + Visit + Visit2	33093.42	33131.76
30	Y ~ B + Visit + Visit2	31918.13	31956.48
31	Y ~ Visit + Visit2	33190.61	33222.56

Шаг 02: Выбираем лучшую модель по критериям AIC и BIC.

```
> # take the best model for AIC criteria
> best_modelAIC <- IC_table[IC_table$AIC == min(IC_table$AIC), ]
> print(best_modelAIC)
```

id	model	AIC	BIC
21	Y ~ A*B + B*Visit + B*Visit2	31297.06	31360.96

```

> # take the best model for BIC criteria
> best_modelBIC <- IC_table[IC_table$BIC == min(IC_table$BIC), ]
> print(best_modelBIC)

```

id	model	AIC	BIC
21	Y ~ A*B + B*Visit + B*Visit2	31297.06	31360.96

Шаг 03: Провести исследование влияния факторов A, B и времени наблюдения на значение времени наблюдаемой характеристики в самой лучшей модели.

Самое лучшей модель: Y ~ A*B + B*Visit + B*Visit2

$$\eta_{ijkl} = \mu + \alpha_i^A + \alpha_j^B + \alpha_k^T + \alpha_l^{T^2} + \alpha_{ij}^{AB} + \alpha_{jk}^{BT} + \alpha_{jl}^{BT^2}$$

```

> # check the parameters inside of the optimal model
> opt_id <- IC_table[IC_table$AIC == min(IC_table$AIC), ]$id
> print(paste("opt-id = ", opt_id))
[1] "opt-id = 21"
> model_opt <- lme(fixed = form[[opt_id]],
+                 random =~ 1|ID, data = datavar9, method = "ML")
> print(model_opt)

```

```

Linear mixed-effects model fit by maximum likelihood
Data: datavar9
Log-likelihood: -15638.53
Fixed: form[[opt_id]]
      (Intercept)          as.factor(A)1
      35.858952          7.516174
as.factor(B)2          Visit
      -5.751165          9.963029
      Visit2 as.factor(A)1:as.factor(B)2
      -2.871588          -8.740373
as.factor(B)2:Visit    as.factor(B)2:Visit2
      -6.010975          1.894432

Random effects:
Formula: ~1 | ID
      (Intercept) Residual
StdDev: 0.000660717 8.425295

Number of Observations: 4405
Number of Groups: 881

```

Значимость параметров оптимальной модели:

```
> # check the significance of the parameters in the optimal model
> anova_opt <- anova(model_opt)
> print(anova_opt)
```

	numDF	denDF	F-value	p-value
(Intercept)	1	3518	83321.19	<.0001
as.factor(A)	1	879	150.82	<.0001
as.factor(B)	1	3518	1653.30	<.0001
Visit	1	3518	67.49	<.0001
Visit2	1	3518	653.27	<.0001
as.factor(A):as.factor(B)	1	3518	294.45	<.0001
as.factor(B):Visit	1	3518	76.02	<.0001
as.factor(B):Visit2	1	3518	155.39	<.0001

- отсутствие влияния фактор A: $H_A: \alpha_i^A = \alpha_{ij}^{AB} = 0$

```
> # study of absence in influence of factor A
> id_m9A <- as.numeric(which(func == "Y ~ B*Visit + B*Visit2"))
> model_m9A <- lme(fixed = form[[id_m9A]], random = ~ 1|ID,
+ data = datavar9, method = "ML")
> anova_m9A <- anova(model_m9A, model_opt)
> print(anova_m9A)
```

	Model	df	AIC	BIC	loglik	Test	L.Ratio	p-value
model_m9A	1	8	31712.15	31763.27	-15848.07			
model_opt	2	10	31297.06	31360.96	-15638.53	1 vs 2	419.0892	<.0001

```
> print(anova_m9A$p-value[2]) # reject HA
[1] 9.906854e-92
```

Отвергает H_A, тогда есть влияния фактора A в наилучшей модели.

- отсутствие влияния фактор B: $H_B: \alpha_j^B = \alpha_{ij}^{AB} = \alpha_{jk}^{BT} = \alpha_{jl}^{BT^2} = 0$

```
> # study of absence in influence of factor B
> id_m9B <- as.numeric(which(func == "Y ~ A + Visit + Visit2"))
> model_m9B <- lme(fixed = form[[id_m9B]], random = ~ 1|ID,
+ data = datavar9, method = "ML")
> anova_m9B <- anova(model_m9B, model_opt)
> print(anova_m9B)
```

	Model	df	AIC	BIC	loglik	Test	L.Ratio	p-value
model_m9B	1	6	33093.42	33131.76	-16540.71			
model_opt	2	10	31297.06	31360.96	-15638.53	1 vs 2	1804.358	<.0001

```
> print(anova_m9B$p-value[2]) # reject HB
[1] 0
```

Отвергает H_B, тогда есть влияния фактора B в наилучшей модели.

- отсутствие влияния фактор времени наблюдения:

$$H_T: \alpha_k^T = \alpha_l^{T^2} = \alpha_{jk}^{BT} = \alpha_{jl}^{BT^2} = 0$$

```

> # study of ausence in influence of time
> model_m9T <- lme(fixed = Y ~ as.factor(A) * as.factor(B), random =~ 1|ID,
+ data = datavar9, method = "ML")
> anova_m9T <- anova(model_m9T, model_opt)
> print(anova_m9T)
      Model df      AIC      BIC    logLik   Test  L.Ratio p-value
model_m9T   1  6 32139.65 32178.00 -16063.83
model_opt   2 10 31297.06 31360.96 -15638.53 1 vs 2 850.5932 <.0001
> print(anova_m9T$p-value[2]) # reject H0
[1] 8.42858e-183

```

Отвергает H_0 , тогда есть влияния фактора времени в наилучшей модели.

Шаг 04: Сравнить результаты и выбор наилучшей модели с учетом случайного эффеута при помощи cAIC.

Модель: $Y \sim A*B + B*Visit + B*Visit2$

```
> # compare results of AIC and cAIC for best model
```

```
> aic_best <- AIC(model_opt)
```

```
> print(aic_best)
```

```
[1] 31297.06
```

```
> caic_best <- cAIC(model_opt)
```

```
> print(caic_best$caic)
```

```
[1] 31303.36
```

10. Посчитать частные и совместные доверительные интервалы (принимает с простой эффект индивида).

Совместные доверительные доверительные интервалы:

```

> # take the confidence interval for the set of model parameters
> print(func[opt_id])
[1] "Y ~ A*B + B*Visit + B*Visit2"
> q10 <- lme(fixed = form[[opt_id]], random =~ 1|ID,
+ data = datavar9, method = "ML")
> intervals(q10, which = "fixed")
Approximate 95% confidence intervals

Fixed effects:
              lower    est.    upper
(Intercept)  35.042048 35.858952 36.675855
as.factor(A)1   6.803030  7.516174  8.229318
as.factor(B)2  -6.897780 -5.751165 -4.604551
Visit          9.072449  9.963029 10.853609
Visit2        -3.084347 -2.871588 -2.658829
as.factor(A)1:as.factor(B)2 -9.738608 -8.740373 -7.742138
as.factor(B)2:Visit  -7.252795 -6.010975 -4.769156
as.factor(B)2:Visit2   1.596742  1.894432  2.192121

```